Aplicação de SVM e MobileNet no Diagnóstico de Esteatose Hepática em Imagens de Ultrassom

Gabriel Oliveira Costa[1], **Helena Ferreira Fernandes**[1], **Wanderson de Souza Pessoa**[1]

[1]ICEI – Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Belo Horizonte, MG – Brasil

Abstract. *This paper proposes an automated system for diagnosing hepatic steatosis from ultrasound images, using two classification approaches: Support Vector Machines (SVM), a shallow classifier, and MobileNet, a lightweight and efficient convolutional neural network. The study addresses the challenge of class imbalance by applying dynamic balancing techniques to enhance model performance. The performance was evaluated using metrics such as accuracy, sensitivity, specificity, precision, and F1-Score. Results showed that the MobileNet model achieved good accuracy and F1-Score, with high sensitivity, which is crucial for avoiding false negatives in medical diagnoses.*

Resumo. *Este artigo propõe um sistema automatizado para o diagnóstico de esteatose hepática a partir de imagens de ultrassom, utilizando duas abordagens de classificação: Support Vector Machines (SVM), um classificador raso, e MobileNet, uma rede neural convolucional leve e eficiente. O estudo aborda o desafio do desbalanceamento de classes, utilizando técnicas de balanceamento dinâmico para melhorar a performance do modelo. O desempenho foi avaliado utilizando métricas como acurácia, sensibilidade, especificidade, precisão e F1-Score. Os resultados mostraram que o modelo MobileNet obteve uma boa acurácia e F1-Score, com alta sensibilidade, crucial para evitar falsos negativos em diagnósticos médicos.*

1. Introdução

A esteatose hepática, também conhecida como doença hepática gordurosa não alcoólica (NAFLD, na sigla em inglês), é a condição no fígado mais prevalente no mundo, afetando uma proporção significativa da população global. Caracterizada pelo acúmulo de gordura no fígado, a condição pode progredir para estágios mais graves, como esteato-hepatite, fibrose e, eventualmente, cirrose hepática, se não for tratada adequadamente.

A biópsia hepática é o padrão de referência para quantificação direta de esteatose hepática em amostras de tecido hepático, mas tem como desvantagem ser um procedimento caro e invasivo que traz um alto risco de complicações sérias. A ultrassonografia é amplamente utilizada como ferramenta de diagnóstico devido ao seu custo acessível, não invasividade e facilidade de aplicação.

No entanto, a análise das imagens de ultrassom para detectar esteatose hepática depende, muitas vezes, de profissionais experientes, sendo suscetível a interpretações subjetivas e variabilidade interobservadores. Isso destaca a necessidade de desenvolver sistemas automatizados que possam oferecer diagnósticos precisos e consistentes, auxiliando médicos na tomada de decisão clínica.

Neste contexto, surge a possibilidade de utilizar técnicas de aprendizado de máquina, que têm mostrado grande potencial para tarefas de classificação em imagens médicas. Este estudo tem como objetivo propor e avaliar um sistema automatizado para o diagnóstico de esteatose hepática a partir de imagens de ultrassom. Para isso, são exploradas duas abordagens principais de classificação:

- Classificador raso (Support Vector Machines - SVM): Um modelo de aprendizado supervisionado baseado em margens ótimas de separação entre classes.
- Classificador profundo (MobileNet): Uma rede neural convolucional leve e eficiente, frequentemente utilizada em aplicações de visão computacional em dispositivos com recursos computacionais limitados.

2. Metodologia

O sistema desenvolvido neste estudo foi inspirado pelo trabalho de Byra et al. (2018), que propôs o uso de transfer learning com redes neurais convolucionais profundas para a avaliação da esteatose hepática em imagens de ultrassom [Byra et al. 2018]

A partir desse estudo, exploramos a utilização de duas abordagens principais de classificação, cada uma com suas características e potenciais: o classificador raso (Support Vector Machines - SVM) e o classificador profundo (MobileNet). A inovação deste trabalho reside no uso e comparação dessas duas técnicas, o que nos permitiu avaliar e comparar o desempenho de modelos tradicionais e modernos no diagnóstico de esteatose hepática. A seguir, detalhamos as principais etapas do desenvolvimento do sistema, começando pela descrição do conjunto de dados utilizado.

2.1. Descrição dos dados

O dataset utilizado no artigo contém imagens de ultrassom em modo B de fígados de 55 pacientes severamente obesos, com média de idade de 40,1 anos e IMC médio de 45,9, sendo 20% homens. Essas imagens foram coletadas no pré-operatório de cirurgias bariátricas, e cada paciente também passou por uma biópsia hepática durante a cirurgia para determinar o nível de esteatose, com base no percentual de hepatócitos infiltrados com gordura.

- **Aquisição das Imagens:**
  - **Equipamento:** GE Vivid E9 Ultrasound System.
  - **Configuração:** Sonda setorial operando a 2,5 MHz, com resolução de 434×636 pixels.
  - **Formato:** Sequências em DICOM correspondendo a um ciclo cardíaco.
- **Total de Imagens:** 550 (10 imagens por paciente, extraídas das sequências para maior diversidade).
- **Distribuição do Nível de Esteatose:** Os fígados com esteatose foram definidos como aqueles com mais de 5% dos hepatócitos afetados, representando 38 pacientes do total.

O dataset está disponível publicamente no repositório Zenodo (`https://doi.org/10.5281/zenodo.1009146`) e inclui as imagens e os resultados das biópsias. Ele foi projetado para pesquisas sobre a avaliação de esteatose hepática em imagens de ultrassom, com um diferencial de fornecer imagens com o rim do lado esquerdo (em vez do lado direito, como no padrão convencional).

2.2. Extração das características

Foi implementada uma interface para facilitar a manipulação e visualização das imagens com as seguintes funcionalidades:

- Leitura e exibição das imagens em tons de cinza com opção de zoom e respectivos histogramas
- Recortar regiões de interesse (ROIs)
- Computar as matrizes de co-ocorrência (GLCM), descritores de textura e Statistical feature matrix de uma ROI
- Geração de ROI normalizada a partir de outras duas ROIs (a primeira região deve ser do fígado e a segunda do córtex renal)
- Classificar uma imagem através dos modelos treinados

Foi gerado uma ROI normalizada para cada imagem do dataset, seguindo o descrito no artigo (link artigo) para calcular o índice hepatorenal HI. Os tons de cinza da ROI do fígado foram ajustados para gerar a ROI normalizada, multiplicando cada valor de tom de cinza pelo HI calculado. Foi gerada uma ROI normalizada para cada imagem do dataset (550 rois), assim como armazenado os seguintes descritores e características de cada ROI em uma planilha(para serem usados futuramente pelo classificador raso):

- 4 GLCM radiais Ci onde i=1,2,4,8 pixels, assim como os descritores de Haralick Entropia e Homogeneidade para cada uma dessas GLCM
- Statistical Feature Matrix (SFM): coarseness, contrast, periodicity e roughness
- HI (índice hepatorenal): razão entre a média de tons de cinza da ROI do fígado e a média dos tons de cinza da ROI do rim

2.3. Estratégia de Avaliação e Métricas

Escolhemos calcular várias métricas para avaliar o desempenho dos modelo, considerando a criticidade do problema:

- **Acurácia**: Mede a proporção de predições corretas entre todas as predições.
- **Sensibilidade** (Recall para a classe positiva): Avalia a capacidade do modelo de identificar corretamente os casos positivos, essencial para evitar falsos negativos em diagnósticos médicos.
- **Especificidade**: Mede a capacidade do modelo de identificar corretamente os casos negativos.
- **Precisão**: Verifica a proporção de predições positivas que são realmente positivas.
- **F1-Score**: Combinação da precisão e da sensibilidade, importante para lidar com datasets desbalanceados.

As métricas escolhidas foram selecionadas para proporcionar uma avaliação abrangente do desempenho do modelo. Elas ajudam a identificar possíveis vieses e oferecem uma análise mais robusta, assegurando que o modelo seja capaz de identificar corretamente tanto os casos positivos quanto negativos, mesmo em cenários com dados desbalanceados.

A sensibilidade, em particular, é crucial, pois, em um sistema de diagnóstico de doenças, o maior objetivo é evitar os falsos negativos, que podem ter consequências prejudiciais para os pacientes.

3. Treinamento dos classificadores

Em ambos os classificadores, foi realizada uma validação cruzada Leave-One-Out (LOO-CV), na qual os classificadores foram treinados e testados utilizando um conjunto de teste composto por 10 imagens de um paciente, enquanto o restante das imagens dos outros pacientes foi usado como conjunto de treinamento. Esse processo foi repetido 55 vezes, uma para cada paciente.

O dataset utilizado apresentava um desbalanceamento de classes, com 38 pacientes com esteatose hepática (classe 1) e 17 pacientes saudáveis (classe 0). Para evitar que o modelo fosse enviesado para a classe majoritária, aplicamos balanceamento dinâmico das classes, ajustando os pesos de forma inversamente proporcional à frequência de cada classe no conjunto de treinamento.

3.1. SVM

O classificador binário raso escolhido foi o SVM (Support Vector Machines), que é um poderoso algoritmo de aprendizado de máquina amplamente utilizado para classificação linear e não linear. SVMs são eficazes pois se concentram em encontrar o hiperplano de separação máximo entre as diferentes classes no recurso alvo, tornando-os robustos para classificação binária[GeeksforGeeks 2024b], que é o que estamos buscando. Foi utilizada a biblioteca Scikit-learn, que é uma biblioteca Python de código aberto que implementa uma variedade de algoritmos de aprendizado de máquina, pré-processamento, validação cruzada e visualização em uma interface unificada.

As características usadas como entrada para os classificadores foram os descritores de Haralick das GLCM calculadas e os descritores das Statistical Feature Matrix.

Foram usados métodos para normalizar as características. Para isso, foi utilizado o RobustScaler da biblioteca SkicitLearn, que remove a mediana e dimensiona os dados de acordo com o intervalo de quartil (padrões para IQR: Intervalo Interquartil). O IQR é o intervalo entre o 1º quartil (25º quantil) e o 3º quartil (75º quantil). A centralização e o dimensionamento acontecem independentemente em cada feature, calculando as estatísticas relevantes nas amostras no conjunto de treinamento. A mediana e o intervalo interquartil são então armazenados para serem usados em dados posteriores usando o método de transformação(para centralizar e dimensionar os dados), de forma que outliers não influenciem a média/variância da amostra de forma negativa.

Foi utilizado a classe SVC da biblioteca SkicitLearn para o classificador SVM[Scikit-learn 2024]. Foi usado grid search para encontrar a melhor combinação de hiperparâmetros para o modelo, com a escolha final sendo pelo kernel RBF (função de base radial), C = 1000 e gamma='auto'.

- Kernel: funções matemáticas que transformam dados não linearmente separáveis em um espaço de alta dimensão, onde se tornam linearmente separáveis, permitindo que o algoritmo encontre uma fronteira de decisão que maximiza a margem entre as classes. O RBF mede a similaridade entre dois pontos baseando-se na distância euclidiana entre eles, sendo capaz de lidar com padrões complexos em dados não lineares.
- C: parâmetro de regularização, com a força de regularização sendo inversamente proporcional ao C. Ele controla o trade-off entre o erro de treinamento e a margem

já que determina a penalidade para dados classificados incorretamente durante o processo de treinamento. [Baeldung 2024]
- Gamma: define até onde a influência de um único exemplo de treinamento alcança. Intuitivamente, um valor de gamma baixo significa que a influência de um único exemplo de treinamento alcança longe, afetando uma região maior do espaço de recursos. Por outro lado, um valor de gamma alto significa que a influência é próxima, afetando apenas a região próxima ao exemplo de treinamento. Em 'auto', é definido como 1/n, send n o número de features. [GeeksforGeeks 2024a]

Tempo de execução: O classificador SVM levou aproximadamente 980 segundos, ou cerca de 16 minutos, para ser treinado utilizando a CPU.

3.2. MobileNet

3.2.1. Ambiente de Desenvolvimento

O desenvolvimento do modelo e o treinamento foram realizados utilizando Python 3.9 e TensorFlow 2.10, escolhidas por sua compatibilidade e estabilidade para desenvolvimento em aprendizado profundo com suporte a GPU. O uso de GPU foi essencial para acelerar o treinamento e o teste do modelo, dado o tamanho das imagens e a complexidade da MobileNet.

Para garantir o funcionamento adequado do TensorFlow com GPU, foram utilizadas as versões CUDA 11.2 e cuDNN 8.1, conforme recomendado pela documentação oficial do TensorFlow [TensorFlow 2024], para evitar incompatibilidades e otimizar o desempenho do modelo.

O modelo foi desenvolvido e treinado em um computador com as seguintes especificações de hardware e sistema operacional:

Placa de Vídeo: NVIDIA GeForce RTX 3050 Laptop GPU (6 GB de memória dedicada). Sistema Operacional: Windows 11.

O uso dessa configuração permitiu explorar os recursos avançados de aceleração de hardware, como paralelização e otimização de cálculos matriciais, fundamentais para lidar com modelos de deep learning complexos como o utilizado neste trabalho.

3.2.2. Desenvolvimento do Modelo

O desenvolvimento do modelo foi realizado com foco em criar uma abordagem robusta e interpretável para classificar as imagens em um problema de diagnóstico médico binário. A seguir, detalhamos as principais etapas do desenvolvimento e justificamos as decisões tomadas.

Pré-processamento de Dados. As imagens utilizadas foram processadas considerando a natureza do problema e as limitações computacionais. As Regiões de Interesse (ROIs) foram extraídas e inicialmente estavam em escala de cinza (grayscale). No entanto, o

modelo MobileNet, utilizado para o fine-tuning, requer imagens em formato RGB, uma vez que foi originalmente treinado no dataset ImageNet, composto por imagens coloridas. Por isso, realizamos a conversão para RGB.

Em seguida, realizamos o redimensionamento das imagens de 28x28 pixels (dimensão original) para 128x128 pixels. Essa decisão foi baseada na necessidade de adequar as imagens ao tamanho máximo suportado pela GPU utilizada, já que o modelo MobileNet, na configuração original do ImageNet, foi treinado com imagens de 244x244 pixels. Redimensionar para 128x128 permitiu balancear a limitação de memória e a tentativa de aproveitar ao máximo a capacidade do modelo.

Arquitetura do Modelo, Fine-Tuning Para o treinamento, utilizamos a MobileNet, pré-treinada no ImageNet, realizando o fine-tuning para adaptar o modelo ao problema específico. A última camada foi substituída por uma com uma função de ativação softmax para classificação binária.

Embora a sigmoid seja uma escolha comum para problemas binários, observamos um melhor desempenho com a softmax, possivelmente porque essa função considera a interação entre as classes de forma mais explícita, o que pode ter facilitado a otimização durante o treinamento.

O modelo foi compilado com o otimizador Adam, um método amplamente utilizado por sua eficiência em ajustar pesos em redes complexas. A função de perda escolhida foi a sparse categorical crossentropy, ideal para problemas de classificação com rótulos inteiros. A métrica inicial utilizada para monitorar o treinamento foi a acurácia.

Estratégia de Avaliação e Métricas As métricas, definidas anteriormente, foram calculadas a partir de uma supermatriz de confusão, que consolidou os resultados de todos os folds da validação cruzada. A matriz de confusão é uma tabela que mostra a performance do modelo ao comparar as predições com os valores reais, considerando quatro categorias principais: verdadeiro positivo, falso positivo, verdadeiro negativo e falso negativo. No caso da supermatriz de confusão, ela é formada pela combinação das matrizes de confusão de cada fold, o que permite avaliar o desempenho do modelo de maneira global e não apenas com base em um único fold ou em métricas intermediárias. Essa abordagem evita o viés causado por variações específicas de cada fold e proporciona uma visão mais robusta sobre como o modelo se comporta em dados desconhecidos, refletindo seu desempenho de forma mais precisa e confiável.

Seleção de Hiperparâmetros Para determinar os melhores hiperparâmetros, realizamos uma grid search, que testou várias combinações de valores. Essa abordagem sistemática nos permitiu avaliar detalhadamente o impacto de cada configuração no desempenho do modelo. Os critérios de seleção foram baseados em uma métrica composta, com pesos ajustados para refletir a prioridade do problema:

- **50% para acurácia**: Representa o desempenho global do modelo.
- **40% para sensibilidade**: Reflete a importância de identificar corretamente os casos positivos.

- **10% para especificidade**: Auxilia a evitar falsos positivos, embora seja menos crítico que evitar falsos negativos.

Hiperparâmetros Selecionados

- **Learning Rate (1e-3)**: Refere-se à taxa de aprendizado, que determina o tamanho do passo dado pelo modelo ao atualizar seus pesos durante o treinamento. Um valor de 1e-3 foi escolhido por ser relativamente pequeno, permitindo ajustes mais finos nos pesos e evitando oscilações excessivas que poderiam comprometer a estabilidade do treinamento. Taxas de aprendizado maiores resultaram em um treinamento instável, como observado em testes preliminares.
- **Batch Size (55)**: O tamanho do batch é o número de amostras usadas em cada iteração de treinamento. O valor de 55 foi ajustado com base no número de pacientes presentes no dataset, garantindo que cada iteração representasse uma parte significativa dos dados, sem sobrecarregar a memória da GPU, o que poderia prejudicar a performance do treinamento.
- **Épocas (80)**: Refere-se ao número de vezes que o modelo passa por todo o conjunto de treinamento. O valor de 80 foi definido após testes, considerando que era suficiente para que o modelo convergisse para uma solução ótima, sem risco de underfitting. O uso de dropout ajudou a mitigar o risco de overfitting durante esse processo.

  Tamanho de Entrada (128x128): O tamanho da imagem de entrada para a rede neural foi definido como 128x128 pixels. Esse valor foi escolhido para equilibrar as limitações computacionais, uma vez que imagens maiores não caberiam na memória da GPU, e ao mesmo tempo, 128x128 ainda é compatível com a ImageNet, utilizada no pré-treinamento. Dessa forma, conseguimos aproveitar ao máximo as representações aprendidas pela rede na ImageNet, garantindo eficiência no treinamento e na extração de recursos relevantes.
- **Taxa de Dropout (0.5)**: A taxa de dropout especifica a fração de unidades (neurônios) que serão desativadas aleatoriamente durante o treinamento para evitar overfitting. A escolha de 0.5 foi baseada em experimentos preliminares, que mostraram que o modelo sem dropout apresentava um desempenho significativamente melhor no treinamento em comparação com a validação, indicando overfitting.

Além disso, definimos a seed (semente) como 193325074 para garantir a reprodutibilidade dos experimentos. Configurando a seed tanto no NumPy quanto no TensorFlow, assegura-se que os resultados possam ser replicados com os mesmos valores iniciais e condições experimentais.

Tempo de execução: O modelo MobileNet, utilizando os parâmetros mencionados, demorou 270 segundos para ser treinado com o uso da GPU no ambiente de execução descrito anteriormente.

4. Resultados

Nesta seção, apresentamos os resultados obtidos para os modelos SVM e MobileNet, com foco nas métricas de desempenho que refletem o comportamento dos classificadores em relação ao diagnóstico automatizado de esteatose hepática.

4.1. SVM

A acurácia do modelo SVM foi de 69,09%, o que pode ser atribuído a limitações nas regiões de interesse (ROIs) utilizadas no treinamento, bem como ao tamanho reduzido da base de dados. Esses fatores provavelmente afetaram a capacidade do modelo de generalizar adequadamente para diferentes padrões nas imagens de ultrassom.

A sensibilidade de 50% indica que o modelo SVM apresenta dificuldades significativas na identificação de casos positivos, o que é especialmente crítico em contextos de diagnóstico médico, onde é fundamental evitar falsos negativos.

Em relação à especificidade, o valor de 69,16% sugere que o modelo consegue identificar razoavelmente bem os casos negativos, mas esse índice ainda é inferior à sensibilidade, que é mais relevante para evitar falhas no diagnóstico, como os falsos negativos.

Quanto à precisão e ao F1-Score, os valores baixos de 0,59% e 1,17%, respectivamente, indicam que o modelo está cometendo um número elevado de erros, refletindo uma baixa capacidade de distinguir corretamente entre os diferentes tipos de casos. Esses resultados evidenciam a necessidade de melhorias no desempenho do modelo.

Esses resultados mostram que o modelo SVM apresenta dificuldades significativas em equilibrar sensibilidade e precisão, com uma alta taxa de falsos positivos e uma sensibilidade relativamente baixa. Embora a acurácia seja razoável, o modelo não é eficaz em identificar corretamente os casos positivos, o que o torna inadequado para diagnóstico médico automatizado de esteatose hepática.

4.2. MobileNet

O modelo MobileNet apresentou resultados sólidos, com uma acurácia de 88,73%, indicando que a maior parte das predições foi feita corretamente. A acurácia é uma boa métrica geral, mas, mesmo com o balanceamento das classes, ela não captura completamente o desempenho em relação a cada classe individualmente.

A sensibilidade foi de 87,37%, o que é um ótimo resultado para o contexto de diagnóstico médico, onde a prioridade é identificar corretamente os casos positivos (como pacientes com esteatose hepática).

A especificidade ficou em 84,12%, o que indica que o modelo foi eficaz em identificar corretamente os casos negativos (pacientes saudáveis). Isso ajuda a garantir que o modelo não classifique erroneamente pacientes saudáveis como doentes, evitando diagnósticos falsos positivos.

A precisão foi alta, com um valor de 92,48%, o que significa que quando o modelo previu a classe positiva, ele foi correto em 92,48% das vezes. Isso é importante para garantir que o modelo não classifique erroneamente pacientes saudáveis como doentes.

Por fim, o F1-Score alcançou 89,85%, refletindo um bom equilíbrio entre sensibilidade e precisão. O valor elevado do F1-Score indica que o modelo não está apenas priorizando uma métrica em detrimento da outra, mas sim alcançando um bom equilíbrio entre elas.

Esses resultados demonstram que o modelo MobileNet é bem equilibrado e eficiente, com um desempenho robusto tanto em termos de sensibilidade quanto de precisão,

o que o torna adequado para o diagnóstico automatizado de esteatose hepática a partir de imagens de ultrassom.

4.3. Comparação SVM x MobileNet

A seguir, apresentamos uma comparação detalhada entre os modelos SVM e MobileNet, levando em consideração as principais métricas de desempenho, como acurácia, sensibilidade, especificidade e F1-Score. Além disso, as matrizes de confusão para cada modelo são exibidas para ilustrar o comportamento de cada classificador na identificação dos casos positivos e negativos, destacando a capacidade de cada modelo em evitar falsos positivos e falsos negativos.

Método	**Acurácia (%)**	**Sensibilidade (%)**	**Especificidade (%)**	**F1 Score (%)**
SVM	69.09	50.00	69.16	1.17
MobileNet	88.73	87.37	84.12	89.85

Table 1. Comparação dos classificadores

MobileNet

A matriz de confusão para o modelo MobileNet é dada por:

$$\begin{bmatrix} \text{TN} & \text{FP} \\ \text{FN} & \text{TP} \end{bmatrix} = \begin{bmatrix} 296 & 45 \\ 52 & 167 \end{bmatrix}$$

SVM

A matriz de confusão para o modelo SVM é dada por:

$$\begin{bmatrix} \text{TN} & \text{FP} \\ \text{FN} & \text{TP} \end{bmatrix} = \begin{bmatrix} 1 & 169 \\ 1 & 379 \end{bmatrix}$$

A análise comparativa entre os modelos SVM e MobileNet revela diferenças substanciais em termos de desempenho. O MobileNet se destacou significativamente, apresentando uma acurácia de 88,73%, bem superior aos 69,09% obtidos pelo SVM. Além disso, o MobileNet mostrou um equilíbrio notável entre sensibilidade (87,37%) e especificidade (84,12%), refletindo sua capacidade de identificar corretamente tanto os casos positivos quanto negativos, o que é essencial em diagnósticos médicos.

Por outro lado, o SVM apresentou uma sensibilidade de apenas 50%, indicando sua dificuldade em identificar corretamente os casos positivos, o que pode ser crítico para evitar falsos negativos. A especificidade do SVM foi de 69,16%, o que, apesar de razoável, não compensa sua baixa sensibilidade. Além disso, a precisão do SVM foi extremamente baixa (0,59%), resultando em um F1-Score de apenas 1,17%, o que demonstra um desempenho insuficiente em equilibrar sensibilidade e precisão.

As matrizes de confusão ilustram claramente essas diferenças. O MobileNet apresentou 296 verdadeiros negativos (TN), 45 falsos positivos (FP), 52 falsos negativos (FN) e 167 verdadeiros positivos (TP), enquanto o SVM mostrou uma matriz com 1 TN, 169

FP, 1 FN e 379 TP. Esse contraste reforça que, enquanto o MobileNet consegue um bom controle tanto sobre falsos positivos quanto sobre falsos negativos, o SVM tem dificuldades em discriminar corretamente as classes, principalmente devido ao alto número de falsos positivos.

Esses resultados confirmam que o MobileNet é significativamente mais eficaz e equilibrado para o diagnóstico automatizado de esteatose hepática em imagens de ultrassom, superando o modelo SVM em termos de precisão, sensibilidade e especificidade.

5. Conclusão

Neste trabalho, avaliamos o desempenho de dois modelos de aprendizado de máquina, o SVM e o MobileNet, na tarefa de diagnóstico automatizado de esteatose hepática a partir de imagens de ultrassom. Os resultados obtidos demonstraram que o MobileNet superou significativamente o modelo SVM em diversas métricas de desempenho, como acurácia, sensibilidade, especificidade e F1-Score.

O MobileNet se destacou por equilibrar adequadamente a identificação de casos positivos e negativos, apresentando excelentes resultados em sensibilidade (87,37%) e especificidade (84,12%). Esses índices tornam o modelo mais adequado para o contexto de diagnóstico médico, onde é fundamental a precisão na distinção entre os diferentes tipos de casos.

Por outro lado, o modelo SVM teve dificuldades em identificar corretamente os casos positivos, apresentando uma sensibilidade de apenas 50%, além de um elevado número de falsos positivos. Esses problemas comprometem sua eficácia em ambientes médicos, nos quais a precisão no diagnóstico é crucial. Adicionalmente, o SVM apresentou um desempenho mais lento, com um tempo de treinamento de 980 segundos, devido à falta de suporte para GPU nas bibliotecas utilizadas.

Vale ressaltar que os resultados poderiam ser ainda mais robustos com o uso de um conjunto de dados maior e mais diversificado, contendo imagens de diferentes estágios da doença e com variações na qualidade das imagens. O aumento do tamanho do dataset, bem como a aplicação de técnicas de aumento de dados, poderia melhorar a generalização dos modelos e potencialmente aumentar a precisão das previsões.

Esses resultados sugerem que, embora o SVM possa ser útil em alguns cenários, o MobileNet oferece desempenho superior na tarefa de classificação de esteatose hepática em imagens de ultrassom. O uso de redes neurais convolucionais como o MobileNet, aliado a uma melhor generalização, se destaca como uma abordagem promissora para o desenvolvimento de sistemas automatizados de diagnóstico médico.

References

Baeldung (2024). Svm c parameter in machine learning. `https://www.baeldung.com/cs/ml-svm-c-parameter`. Acessado em: 26 nov. 2024.

Byra, M., Styczynski, G., Szmigielski, C., Kalinowski, P., Łukasz Michałowski, Paluszkiewicz, R., Ziarkiewicz-Wróblewska, B., Zieniewicz, K., Sobieraj, P., and Nowicki, A. (2018). Transfer learning with deep convolutional neural network for liver steatosis assessment in ultrasound images. *International Journal of Computer Assisted Radiology and Surgery*, 13(11):1895–1903. Acessado em: 26 nov. 2024.

GeeksforGeeks (2024a). Gamma parameter in svm. https://www.geeksforgeeks.org/gamma-parameter-in-svm/. Acessado em: 26 nov. 2024.

GeeksforGeeks (2024b). Support vector machine algorithm. https://www.geeksforgeeks.org/support-vector-machine-algorithm/. Acessado em: 26 nov. 2024.

Scikit-learn (2024). Support vector machines — scikit-learn documentation. https://scikit-learn.org/1.5/modules/svm.html. Acessado em: 26 nov. 2024.

TensorFlow (2024). Suporte a gpus. https://www.tensorflow.org/install/gpu?hl=pt-br. Acessado em: 26 nov. 2024.